

Alex-Fin 模型架构详解

多频率图网络 混合专家与 GRPO 策略

整理自作者提供的五章架构稿。保留原有模型设定、公式编号与表格关系。卡尔玛比率的原式存在截断，详见文末来源说明与作品目录的 source-map.md。作品导读与来源索引 · 2026-09-20 · CC BY-NC-SA 4.0

第一章 问题定义与研究范式

本章严格遵循投资组合优化领域的通用学术规范，将动态投资组合优化任务形式化为标准的离散时间马尔可夫决策过程（Markov Decision Process, MDP），为所提深度强化学习框架提供标准化的序列决策理论支撑。本章明确核心研究目标为训练具备端到端自主资产配置能力的DRL智能体，均值-方差优化（Mean-Variance Optimization, MVO）模型仅作为合规的策略对照基准，仅保证对照实验的基础公平性（同资产池、同时序区间、无未来信息泄露），不强行实现二者的信息对等与目标统一。同时，本章构建以风险调整后收益为核心的投资绩效评价体系，明确**微分夏普比率（Differential Sharpe Ratio, DSR）**为贯穿训练、验证、评估全链路的唯一核心指标，为全文研究提供统一的理论框架与评价标准。

1.1 序列决策问题的MDP形式化

本研究将动态投资组合优化任务严格形式化为离散时间马尔可夫决策过程，核心优化目标为最大化无限时域下的期望累计折扣奖励，为模型端到端学习提供标准化的序列决策框架：

$$\max_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) \right] \quad (1.1)$$

式中各参数定义如下：

- π_{θ} 为带参数 θ 的随机策略，实现市场状态到投资组合动作的端到端概率映射；
- $\gamma \in (0, 1)$ 为折扣因子，本研究固定为 $\gamma=0.9$ ，适配日度调仓的投资组合决策场景，平衡即时奖励与未来奖励的相对重要性，既不过度弱化长期收益的影响，也不放大短期噪声的干扰；
- $s_t \in S$ 为 t 时刻的系统状态空间， $a_t \in A$ 为 t 时刻的投资组合动作空间， $R(\cdot)$ 为单步即时奖励函数。

本研究对MDP五要素的定义与MVO框架保持基础的对照公平性：动作空间与MVO的权重优化目标维度对齐，状态空间包含MVO输入的核心收益特征，奖励函数以风险调整后收益为核心，保障二者实证对比的基础严谨性，核心研究目标聚焦于DRL智能体自主资产配置能力的优化，而非二者的对等性对比。

1.2 核心术语严格定义

本章所有核心术语100%遵循《Deep Reinforcement Learning for Optimal Portfolio Allocation》原文定义，无任何自定义修改，严格界定如下：

- Step（时间步）：对应一个独立的交易周期，本研究固定为1个交易日，是模型最小的决策与执行单元。每个step内，智能体完成「观测市场状态→执行调仓动作→获得即时奖励→状态转移」的完整MDP闭环，一个step内仅能执行一次调仓决策；
- Episode（轨迹/回合）：定义为一个连续、固定长度的回测窗口，包含 T 个顺序执行的step，基准设置为 $T = 252$ 个交易日（1个完整交易年）。每个episode以等额现金、零持仓的初始状态 s_0 启动，严格在第 T 步终止，仅当组合净值归零才会提前终止；
- Epoch（训练轮次）：定义为对整个训练数据集的一次完整遍历，训练数据集由所有不重叠的历史episode窗口组成。每个epoch内，完成所有训练episode的轨迹采样、全量轨迹数据收集、梯度更新、验证集性能评估的完整流程。

1.3 投资绩效评价指标体系

本研究构建以风险调整后收益为核心的投资绩效评价体系，完全符合量化投资领域的通用研究规范，明确DSR为全链路唯一核心指标，贯穿模型训练、验证、评估全流程，具体指标与形式化定义如表1-1所示。

表1-1 模型投资绩效评价指标体系

评价维度	核心指标	形式化定义
核心风险调整后收益指标	微分夏普比率（DSR）	单步DSR定义见第五章式(5.4)，全周期累积DSR为单步值的时序加总，为训练、验证、评估全链路核心基准
	年化夏普比率	$\text{Sharpe Ratio} = \frac{\mathbb{E}[R_p - R_f]}{\sigma_p}$ ，其中 R_p 为组合日度收益， R_f 为无风险利率， σ_p 为组合收益波动率
收益与风险指标	年化收益率	$\text{Annual Return} = \left(\frac{\text{PortVal}_T}{\text{PortVal}_0} \right)^{252/T} - 1$ ，其中 PortVal_t 为 t 时刻组合净值
	最大回撤	$\text{MDD} = \max_{\tau \in [0, T]} \left(\frac{\text{PortVal}_T - \text{PortVal}_{\tau^*}}{\text{PortVal}_{\tau^*}} \right)$ ，其中 $\tau^* = \operatorname{argmax}_{t \in [0, \tau]} \text{PortVal}_t$
	卡尔玛比率	原稿公式在分母起始位置截断，原文片段及待核事项见图表与版本索引。
交易成本与流动性指标	组合换手率	$\text{Turnover} = \frac{1}{T} \sum_{t=1}^T \omega_t - \omega_{t-1} _1$
	信息比率	$\text{Information Ratio} = \frac{\mathbb{E}[R_p - R_m]}{\sigma_{p-m}}$ ，其中 R_m 为MVO基准策略收益， σ_{p-m} 为超额收益波动率

第二章 多频率金融时空关联网络构建

金融市场数据天然具备多频率层级特性：不同时间分辨率的金融数据承载着差异化的市场信息，秒级与分钟级数据反映盘口订单流、日内分时波动的微观市场结构，小时级与日级数据刻画资金轮动、行业日间轮动的中短期交易规律，周级、月度与季度数据捕捉产业景气度、宏观经济周期的长期趋势。本章基于图形LASSO-Diebold-Yilmaz（GLASSO-DY）框架，为全频率维度构建独立的有向风险溢出时空网络，为后续图神经网络建模提供具备严格经济学含义的拓扑约束，完整保留DY风险溢出指标的核心价值。所有网络构建过程严格遵循因果性原则，仅采用 t 时刻之前的历史数据滚动估计，杜绝未来信息泄露。

同时，本章严格遵循FinCast (arXiv:2508.19609) 原生范式，构建全模型复用的统一指数加权移动平均 (Exponentially Weighted Moving Average, EWMA) 递归更新体系，实现多频率特征的标准化平滑与去冗余处理；采用**离散频率索引+可学习频率嵌入**机制实现异频特征的维度对齐，全程保留各频率原生时间粒度，不做任何上采样、重复填充、下采样操作，完全规避传统跨频率处理带来的结构冗余与信息失真问题；仅采用FinCast原生的特征因果对齐方案，不引入其他对齐设计，不新增任何针对极端场景的软对齐、分布校准、异常值鲁棒性专项机制。

2.1 多频率时空网络的数学定义

定义1 (多频率金融时空网络) 本文将跨频率、跨资产的金融市场系统形式化为四元组 $G = (V, \mathcal{E}, A, \mathcal{F})$ ，其中各分量严格定义如下：

- $\mathcal{V} = v_1, v_2, \dots, v_N$ 为节点集合，每个节点对应一个行业指数或标的资产；
- 1. $\mathcal{E} \subseteq V \times V \times \mathcal{F}$ 为带频率属性的有向边集合，边 (v_i, v_j, f) 表示频率 f 下资产 i 对资产 j 的风险溢出关系；
- 2. $A = \{A^f \mid f \in \mathcal{F}\}$ 为分频率空间邻接矩阵集合， $A^f \in \mathbb{R}^{N \times N}$ 为频率 f 下的风险溢出邻接矩阵；
- 3. $\mathcal{F} \in \mathbb{R}^{T \times N \times d \times |\mathcal{F}|}$ 为多频率节点特征张量， $T = 60$ 为历史回看窗口， d 为单频率特征维度， $\mathcal{F} = 0, 1, 2, 3, 4, 5, 6$ 分别对应秒级、分钟级、小时级、日级、周级、月度、季度7类金融数据，全程保留各频率原生时间粒度，不做跨频率上采样与重复填充。

2.2 全局频率索引规则与可学习频率嵌入

为解决异频特征的空间维度异构问题，本文严格遵循FinCast原生范式，通过**全局固定离散频率索引+可学习嵌入向量**实现异频特征区分与维度对齐，全程不改变各频率原生时间粒度，实现一次嵌入、全链路复用。

2.2.1 全局固定频率索引映射

全链路所有模块均采用唯一、不可变更的频率索引映射规则，确保频率属性的全链路一致性，具体映射关系如表2-1所示。

表2-1 全局频率索引与对应金融属性

全局固定索引	频率类型	原生时间粒度	核心金融信号属性
0	秒级	秒级	盘口订单流、逐笔成交微观结构信号
1	分钟级	分钟级	日内分时波动、高频量价资金流信号
2	小时级	小时级	日内趋势、半日资金轮动信号
3	日级	日度	日间交易、行业日度轮动信号
4	周级	周度	周度板块轮动、中短期产业趋势信号
5	月度	月度	月度宏观数据、产业景气度周期信号
6	季度	季度	季度财报、宏观经济长周期信号

2.2.2 可学习频率嵌入层实现

本文采用标准可学习嵌入层实现异频特征的维度对齐，核心设计如下：

- 层结构：采用nn.Embedding(num_freqs=7, d_model=256)实现，num_freqs覆盖7类全局频率索引，d_model与本文全局隐藏层维度256完全对齐，确保嵌入叠加后特征维度统一，无需额外维度变换。
- 初始化方式：嵌入权重采用**均值为0、标准差为0.02的正态分布**随机初始化，保障训练初始阶段的梯度稳定性。
- 训练规则：嵌入层权重随模型全链路端到端联合训练，无参数冻结、无人工预设约束，完全由数据驱动学习不同频率的专属时序模式，适配本文「无硬编码、纯数据驱动」的核心研究范式。

2.2.3 嵌入叠加方式与全链路复用规则

严格遵循逐Token逐元素相加的叠加方式，而非特征拼接、全局共享嵌入，核心执行规则为：

1. 对索引0-6对应频率数据生成的所有Patch Token，统一叠加对应索引的频率嵌入向量；
2. 叠加时机固定在「分块实例归一化→线性投影生成Patch Token」之后，确保每个Token从生成的第一时间，就携带专属的、不可剥离的频率身份标识；
3. 叠加频率嵌入后的Token，随特征提取流程完整贯穿GLASSO-DY拓扑构建、GNN时空特征提取、MoE自适应提纯、GRPO强化学习决策全链路，为全流程频率引导提供统一的特征锚点。

2.3 适配FinCast范式的前置分块实例归一化

为适配后续图神经网络与混合专家模块的输入要求，本文严格遵循FinCast官方原生范式，在Token化前置环节执行分块级实例归一化，为全链路特征处理提供无尺度偏差的标准化基础，具体流程如下：

- 非重叠分块处理：对索引0-6对应频率的原始时序序列，按照资产节点进行非重叠固定长度分块，分块长度与频率原生粒度强绑定，具体设置为：秒级 $P=3600$ 、分钟级 $P=60$ 、小时级 $P=20$ 、日级 $P=5$ 、周级 $P=4$ 、月度 $P=3$ 、季度 $P=4$ ；若原始序列长度无法被 P 整除，仅对**序列尾部**做零填充，保证所有输入序列的分块数量完全一致，同时严格恪守时序因果性，避免头部填充对历史时序逻辑的破坏。

- 分块级实例归一化：对每个资产、每个频率的独立分块，执行专属的实例归一化，消除不同资产、不同指标的量纲差异，避免尺度偏差干扰模型特征学习，FinCast原生公式为：

$$\bar{X}_{n,p} = \frac{X_{n,p} - \mu_n}{\sigma_n + \epsilon} \quad (2.1)$$

其中， $X_{n,p}$ 为第 n 个分块内第 p 个时间步的原始数值， $\mu_n = \frac{1}{P} \sum_{p=1}^P X_{n,p}$ 为第 n 个分块的均值， $\sigma_n = \sqrt{\frac{1}{P} \sum_{p=1}^P (X_{n,p} - \mu_n)^2}$ 为第 n 个分块的标准差， $\epsilon = 1e-8$ 为数值稳定性修正项。

- 线性投影生成Token嵌入：归一化后的二维分块，通过可学习的线性投影层映射为固定维度的一维隐向量，生成基础Patch Token嵌入，与2.2节对应索引的可学习频率嵌入叠加后，直接作为本章GLASSO-DY估计与后续图神经网络的节点级输入特征，严格遵循「FinCast归一化→Token化→感知层特征提取」的核心架构链路。

2.4 基于GLASSO-DY的分频率独立动态有向风险溢出邻接矩阵构建

针对传统LASSO-VAR-DY框架存在的重复稀疏化、线性假设约束、辅助修正矩阵破坏风险溢出有向性三大核心缺陷，本文采用「**图形LASSO (Graphical LASSO, GLASSO) 稀疏估计+DY有向分解**」的**单阶段稀疏化方案**，为索引0-6对应的7类频率分别构建完全独立的有向风险溢出邻接矩阵，7个矩阵完全并行、互不融合，为后续同频率的特征提取提供严格的经济学先验约束。本方案移除对称辅助修正矩阵，在保留风险溢出经济学可解释性的同时，彻底解决结构冗余与对称缺陷问题，完整保留DY风险溢出指标的核心价值。

2.4.1 分频率独立GLASSO稀疏精度矩阵估计

对索引0-6对应的7类频率数据，**分别独立执行图形LASSO估计**，为每个频率生成专属的稀疏精度矩阵，核心设计如下：

- 每个频率的GLASSO估计，仅使用该频率原生粒度、 t 时刻之前的历史数据，估计结果与该频率的Token+频率嵌入——绑定，不做跨频率的矩阵融合与信息共享；
- 精度矩阵的非零元素，严格对应该频率原生粒度下资产间的条件依赖关系，为后续同频率的GNN空间注意力模块，提供具备明确经济学含义的拓扑约束；
- 7个频率的GLASSO估计完全并行、独立执行，惩罚参数 λ 通过该频率专属的滚动时间序列交叉验证确定，无跨频率参数共享。

对于每个频率 f （对应索引0-6）下的滚动窗口资产收益序列 $Z^f \in \mathbb{R}^{T \times N}$ （ T 为滚动窗口长度，仅用 t 时刻之前的历史数据），定义其协方差矩阵为 Σ^f ，精度矩阵为 $\Omega^f = (\Sigma^f)^{-1}$ 。通过图形LASSO估计稀疏精度矩阵的目标函数为：

$$\min_{\Omega^f \succ 0} \left(\text{tr}(\Sigma^f \Omega^f) - \log \det(\Omega^f) + \lambda \|\Omega^f\|_1 \right) \quad (2.2)$$

其中：

1. $\text{tr}(\cdot)$ 为矩阵的迹, $\det(\cdot)$ 为矩阵的行列式, $\Omega^f > 0$ 保证精度矩阵正定;
2. λ 为LASSO惩罚参数, 通过该频率专属的滚动时间序列交叉验证确定;
3. $|\cdot|_1$ 为L1范数, 将无统计显著性的条件依赖系数压缩至0, 实现关键关联的一次性稀疏筛选, 避免重复稀疏化带来的冗余。

2.4.2 分频率独立DY有向风险溢出分解

基于每个频率独立估计的稀疏精度矩阵 Ω^f , 本文保留DY框架最核心的有向风险溢出刻画能力, 重构广义预测误差方差分解计算逻辑, 彻底摆脱对VAR模型的依赖, 为每个频率独立生成专属的风险溢出强度矩阵。定义频率 f 下, 资产 j 对资产 i 的向前 H 期有向风险溢出强度为:

$$d_{ij}^{f,H} = \frac{\sigma_{jj}^{-1} \cdot (\Omega_{ij}^f)^2}{\sum_{k=1}^N \sigma_{kk}^{-1} \cdot (\Omega_{ik}^f)^2} \quad (2.3)$$

其中 σ_{jj} 为资产 j 在该频率下收益序列的无条件方差。该公式与传统DY分解的经济学含义完全等价, 衡量资产 j 的风险冲击对资产 i 预测误差方差的贡献占比, 且完美保留了风险溢出的非对称有向性 ($d_{ij}^{f,H} \neq d_{ji}^{f,H}$)。

对溢出强度进行行标准化, 保证每行和为1, 对角线置0, 构建该频率专属的主邻接矩阵 $A^{f,risk}$:

$$\tilde{d}_{ij}^{f,H} = \frac{d_{ij}^{f,H}}{\sum_{j=1}^N d_{ij}^{f,H}}, \quad i \neq j \quad (2.4)$$

$$A_{ii}^{f,risk} = 0 \quad (2.5)$$

2.4.3 分频率最终邻接矩阵构建

本文直接移除基于余弦相似度的对称辅助修正矩阵, 避免其破坏DY风险溢出的有向性核心价值。后续空间注意力模块将通过图注意力网络的自适应权重, 补充线性风险溢出无法覆盖的时变非线性关联, 实现经济学先验与数据驱动建模的有机结合。最终频率 f (对应索引0-6) 下的邻接矩阵为:

$$A_t^{f,final} = A_t^{f,risk} \quad (2.6)$$

7类邻接矩阵分别与对应频率的Token序列绑定, 随携带频率嵌入的Token同步输入后续MB-PSTSA-GNN模块, 全程不做拓扑矩阵的跨频率融合, 保障经济学先验的全链路有效性。该矩阵仅采用 t 时刻之前的历史数据滚动估计, 严格规避未来信息泄露。

2.5 统一的EWMA递归更新体系

本文构建全模型复用的指数加权移动平均 (EWMA) 递归更新体系, 采用与《Deep Reinforcement Learning for Optimal Portfolio Allocation》基准论文对齐的衰减系数 $\eta = 2/253$, 平滑系数采用RiskMetrics经典值 $\lambda = 0.94$, 与固定 $\gamma=0.9$ 的风险偏好完全对齐, 实现一次计算、全模型复用, 消除重复计算冗余, 实现模型的去冗余优化。

统一递归公式: 对于任意需平滑的时序变量 x_t , 其一阶矩 μ_t 和二阶矩 V_t 的更新规则为:

$$\begin{cases} \mu_t = (1 - \eta) \mu_{t-1} + \eta x_t \\ V_t = (1 - \eta) V_{t-1} + \eta (x_t - \mu_t)^2 \end{cases} \quad (2.7)$$

该统一体系同时服务于：

1. 全频率节点特征的标准化平滑，消除线性相关的冗余特征；
2. 市场湍流指数与波动率指标的统一计算，避免重复滚动窗口运算；
3. 全频率GLASSO-DY邻接矩阵的滚动权重更新，降低重复矩阵运算的计算冗余；
4. 第五章微分夏普比率（DSR）奖励函数的一阶矩、二阶矩递归计算，保障全模型统计量一致性。

第三章 多频率并行时空分离注意力图神经网络特征提取模块

为有效解耦捕捉多频率金融数据的时序依赖规律与截面空间关联特征，解决传统串行时空耦合架构的信号混叠、特征过平滑、多分支同质化等核心问题，本章设计多频率并行时空分离注意力图神经网络（Multi-Branch Parallel Spatio-Temporal Separated Attention Graph Neural Network, MB-PSTSA-GNN）。本模块严格遵循并行式时空分离注意力范式，完整保留时空分离自注意力的核心架构；为索引0-6对应的7类频率分别构建完全独立的特征提取分支，采用全量非差异化输入设计，为所有分支提供对应频率的原生输入特征，无人工预设的特征裁剪；同时构建时空融合统一注意力层，实现时序规律与空间关联的端到端联合学习，彻底去除以中频为核心锚点的硬编码约束，通过**原生粒度保留+全局时序因果掩码+全连接多向同步交叉注意力机制**实现跨频率信号的高效交互，解决同质化分支与重复权重学习问题，完美适配本文「无硬编码、纯数据驱动」的核心研究范式。

本模块采用单层MB-PSTSA-GNN架构，其核心设计目标不仅在于避免多层堆叠导致的特征过平滑，更在于四大金融场景专属适配性：一是严格遵循时空分离范式，解耦时序依赖与空间关联，避免多频率信号混叠；二是仅聚合一阶直接风险溢出邻居，完整保留分频率GLASSO-DY邻接矩阵的经济学先验与可解释性，避免多层GNN导致的风险溢出含义丢失；三是适配金融数据低信噪比特性，仅做一次邻域信息聚合，最大程度保留原始特征中的有效决策信号，避免噪声放大；四是完美保留不同资产节点的特征区分度，为后续投资组合权重分配提供差异化的决策依据。

3.1 模块整体架构

MB-PSTSA-GNN由**全频率独立并行时空双分支模块、时空融合统一注意力层、全连接多向同步交叉注意力融合模块、特征提纯输出层**四部分构成，整体架构严格遵循时空分离、频率解耦、端到端学习的设计原则，输入为第二章输出的FinCast标准化Token嵌入特征，输出为多频率时空融合特征，直接输入第四章混合专家模块，具体流程如下：

- 全频率独立并行时空双分支模块：为索引0-6对应的7类频率数据分别构建完全独立的特征提取分支，每个分支包含并行的因果掩码时序自注意力与轻量级自适应GAT空间注意力子分支，二者接收对应频率的全量非差异化输入，分别解耦捕捉该频率原生粒度下的时序规律与空间关联；
- 时空融合统一注意力层：整合每个频率分支内时序自注意力、空间自注意力的输出，在统一的注意力框架内实现时空特征的联合建模，自适应学习时序与空间维度的交互权重，无人工预设的融合规则；
- 全连接多向同步交叉注意力融合模块：100%保留本文核心的全连接多向同步交叉注意力机制，实现7类频率特征的双向同步交互，捕捉跨频率的信号传导效应，完全基于数据驱动实现跨频率特征融合，无任何时间步硬对齐操作；

- 特征提纯输出层：通过层归一化与残差连接，对融合后的多频率特征进行提纯，输出统一的多频率时空融合特征。

模型基础超参数设置如下：单层架构，每层设置8头注意力机制，隐藏层维度 $D_{model} = 256$ ，Dropout丢弃率设置为0.1，缓解模型过拟合。

3.2 全频率独立并行时空双分支设计

为索引0-6对应的7类频率，分别构建**完全独立、结构一致、并行计算**的特征提取分支，7个分支互不干扰、无参数共享，从输入源头保障频率属性的纯粹性，避免多频率信号混叠。

3.2.1 无硬编码因果掩码时序自注意力分支

本分支为时序专属模块，遵循单资产独立计算、全量非差异化输入、全链路因果掩码约束原则，仅保留下三角因果掩码，让模型自主学习时序依赖与趋势变化，解决人工约束导致的泛化能力受限问题。

对于频率 f （对应索引0-6）下的节点特征序列 $H^f = [h_1^f, h_2^f, \dots, h_T^f] \in \mathbb{R}^{T \times N \times D_{model}}$ ，本分支采用标准多头自注意力架构，全程施加下三角因果掩码 M^{time} ，严格屏蔽当前时刻 t 之后的所有未来信息，无任何其他人工约束：

$$M_{ij}^{time} = \begin{cases} 0, & j \leq i \\ -\infty, & j > i \end{cases} \quad (3.1)$$

其中 i 为当前时刻 t ， j 为历史时刻，仅允许当前时刻关注历史信息，杜绝未来信息泄露。

基于因果掩码，本分支的多头自注意力计算流程如下：

$$[Q^{f,time}, K^{f,time}, V^{f,time}] = H^f W_{qkv,time}^f \quad (3.2)$$

$$\text{Scores}^{f,time} = \text{softmax} \left(\frac{Q^{f,time} K^{f,time\top}}{\sqrt{d_k}} + M^{time} \right) \quad (3.3)$$

$$H^{f,time} = \text{Scores}^{f,time} V^{f,time} \quad (3.4)$$

其中 $W_{qkv,time}^f$ 为线性投影矩阵， $d_k = D_{model}/H$ 为单注意力头维度， $H^{f,time} \in \mathbb{R}^{T \times N \times D_{model}}$ 为时序注意力分支的最终输出。该设计完全由数据驱动，无任何人工预设的注意力偏置，使模型能够自适应捕捉该频率原生粒度下金融时序中任意形式的有效规律，避免人工硬编码带来的信号遗漏与模型偏见；Token中携带的频率嵌入全程参与注意力计算，引导模型自适应学习该频率专属的时序模式。

3.2.2 轻量级自适应GAT空间注意力分支

本分支为空间专属模块，遵循单时间截面独立计算、全量非差异化输入、单层结构防过平滑原则，基于对应频率专属的GLASSO-DY有向邻接矩阵做拓扑约束，聚合跨资产风险关联，避免多层GNN堆叠导致的节点特征趋同与经济学含义丢失。

本分支与时序注意力分支接收完全一致的全量非差异化输入，无任何人工预设的特征裁剪，仅采用单层多头GAT架构，同时通过该频率专属的GLASSO-DY邻接矩阵掩码非邻居节点，保留风险溢出的经济学先验约束。首先将最终邻接矩阵 $A_t^{f,final}$ 扩展到多头形式 $A^{f,expand} \in \mathbb{R}^{H \times N \times N}$ ，每个注意力头共享相同的拓扑结构，但学习独立的注意力权重。

对于每个节点 v_i ，第 k 个注意力头首先计算其与邻居节点 v_j 的注意力系数，全程不引入跨时间的时序信息，严格遵循时空分离原则：

$$e_{ij}^{f,k} = \text{LeakyReLU}\left(a^{f,k} \left[W^{f,k} H_{t,i}^f \parallel W^{f,k} H_{t,j}^f \right] \right) \quad (3.5)$$

其中 $\parallel$ 为向量拼接操作， $a^{f,k}$ 为第 k 个注意力头的注意力向量， $W^{f,k}$ 为对应的线性变换矩阵， $H_{t,i}^f$ 为 t 时刻资产 i 的全量输入节点特征。

通过该频率专属的GLASSO-DY邻接矩阵掩码非邻居节点，并对注意力系数进行归一化，无任何人工硬编码的关联约束：

$$\alpha_{ij}^{f,k} = \frac{\exp\left(e_{ij}^{f,k}\right) A_{ij}^{f,final}}{\sum_{l \in \mathcal{N}(i)} \exp\left(e_{il}^{f,k}\right) A_{il}^{f,final}} \quad (3.6)$$

其中 $\mathcal{N}(i)$ 为节点 v_i 的邻居集合，由该频率专属的GLASSO-DY邻接矩阵确定，仅在存在风险溢出关联的资产间进行信息聚合。

最终聚合邻居信息，更新节点的空间特征表示，拼接多头注意力输出得到空间分支的最终结果：

$$h_i^{f,k} = \sigma\left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}^{f,k} W^{f,k} H_{t,j}^f\right) \quad (3.7)$$

$$H^{f,space} = \text{Concat}(h^{f,1}, h^{f,2}, \dots, h^{f,H}) \quad (3.8)$$

其中 $H^{f,space} \in \mathbb{R}^{T \times N \times D_{model}}$ 为空间注意力分支的最终输出。Token中携带的频率嵌入同步参与注意力系数计算，强化同频率下资产关联的特征区分度。

3.3 时空融合统一注意力层

针对传统时空串行架构的信号混叠问题，本文构建时空融合统一注意力层，为每个频率分支独立整合时序与空间自注意力输出，实现二者端到端联合建模，自适应学习交互权重。

本层采用门控残差融合机制，构建单频率内的统一时空融合表示，形式化定义如下：

$$g_{time} = \sigma\left(\text{Linear}(H^{f,time})\right), \quad g_{space} = \sigma\left(\text{Linear}(H^{f,space})\right) \quad (3.9)$$

$$\tilde{H}^{f,st} = g_{time} \odot H^{f,time} + g_{space} \odot H^{f,space} \quad (3.10)$$

$$H^{f,fuse} = \text{LayerNorm}\left(H^f + \text{Dropout}(\tilde{H}^{f,st})\right) \quad (3.11)$$

其中 $\sigma(\cdot)$ 为Sigmoid激活函数， $\odot$ 为逐元素乘积， H^f 为原始全量输入特征，通过残差连接保证训练过程中的梯度稳定性， g_{time} 与 g_{space} 为模型自主学习的门控权重，自适应平衡该频率下时序与空间特征的贡献。融合后的 $H^{f,fuse} \in \mathbb{R}^{T \times N \times D_{model}}$ 为该频率分支的时空融合统一特征表示，仍完整携带对应频率的嵌入标识，无任何频率属性的稀释与丢失。

3.4 全连接多向同步交叉注意力融合模块

本环节**100%保留本文核心的全连接多向同步交叉注意力机制**，彻底删除原设计中高低频强制对齐到中频的硬编码操作，通过「时间戳标注+全局时序因果掩码」实现原生粒度下的无失真跨频率交互，彻底杜绝未来信息泄露，同时完全保留跨频率信号的领先-滞后关系。

3.4.1 前置因果性时间锚定（无硬对齐、无信息损失）

不改变7类频率的原生时间粒度，仅为每个Token标注唯一的交易时间戳，不做任何GRU聚合、线性投影平铺等时间步对齐操作，仅通过全局时序因果掩码实现跨频率的时序约束：

- 无论哪个频率的Token作为Query，仅允许关注所有频率中**时间戳早于当前Query时间戳**的Key-Value Token，彻底屏蔽未来信息，完全符合量化研究的因果性铁律；
- 示例：日度t时刻（索引3）的Token作为Query时，仅能关注t时刻之前的所有秒级、分钟级、小时级历史Token，以及t时刻之前的所有周度、月度、季度完整历史Token，不引入任何同期或未来数据。

3.4.2 全连接多向同步交叉注意力原生机制完整落地

严格遵循本文核心设计，7个频率的特征同时作为Query、Key、Value，每个频率的特征都与另外6个频率完成双向同步信息交互，仅通过一次注意力计算完成全频率跨频融合，核心形式化逻辑与本文核心设计完全对齐，仅补充频率感知的适配优化：

1. 对7类频率的时空融合特征，先保留其原生时间维度与携带的频率嵌入，拼接为全局Key-Value矩阵：

$$K^{all} = \text{Concat}(H^0, H^1, H^2, H^3, H^4, H^5, H^6)$$

$$V^{all} = \text{Concat}(H^0, H^1, H^2, H^3, H^4, H^5, H^6)$$

其中 H^0 至 H^6 分别为索引0-6对应频率的时空融合特征，全程携带对应索引的频率嵌入。

2. 分别以7个频率的特征为Query，执行全向交叉注意力计算，以日级特征（索引3）为Query的计算逻辑如下：

$$[Q^3, K^{all}, V^{all}] = [H^3 W_q^3, K^{all} W_k^{all}, V^{all} W_v^{all}]$$

$$\text{Scores}^{3 \leftarrow all} = \text{softmax}\left(\frac{Q^3 K^{all\top}}{\sqrt{d_k}} + M^{causal}\right)$$

$$H^{3, fuse} = \text{Scores}^{3 \leftarrow all} V^{all}$$

其中 M^{causal} 为全局时序因果掩码，严格屏蔽所有时间戳晚于Query的Token，彻底杜绝未来信息泄露；同理可得索引0-6对应频率特征为Query的融合输出，7个频率在一次计算中完成全向同步交互，完全保留本文核心的全连接多向同步交叉注意力设计。

3. 频率嵌入引导优化：在注意力分数计算中，补充频率感知的偏置项，引导模型自主学习不同频率间的领先-滞后关系，强化跨频率信号的有效捕捉，不改变原生交叉注意力的核心逻辑。

3.4.3 跨频率融合特征输出

最终跨频率融合特征为7个频率交叉注意力输出的拼接，与本文核心设计完全一致：

$$H^{cross} = \text{Concat}(H^{0, fuse}, H^{1, fuse}, H^{2, fuse}, H^{3, fuse}, H^{4, fuse}, H^{5, fuse}, H^{6, fuse})$$

融合后的特征中，每个子部分仍完整携带对应频率的嵌入标识，频率属性全程未丢失，为后续MoE模块的专家自专业化分化提供精准的频率锚点。

3.5 特征提纯输出层

通过层归一化与残差连接，对跨频率融合特征进行最终提纯，缓解模型过拟合，保证特征的稳定性与区分度：

$$H^{st} = \text{LayerNorm}\left(H^3 + \text{Dropout}(H^{cross})\right) \quad (3.12)$$

其中Dropout层丢弃率设置为0.1， H^{st} 为模块最终输出的多频率时空融合特征，为后续第四章混合专家模块提供高质量的节点级特征输入。

第四章 市场状态自适应的自专业化MoE混合专家模块

金融市场具有典型的非平稳性与异构性特征，在牛市、熊市、震荡市三类市场制度下，资产收益分布、风险传导路径、量价驱动逻辑呈现本质差异，单一结构的特征提取网络难以同时适配全频率、全市场环境的信号捕捉需求，极易出现市场制度切换时的模型性能断崖式退化。与此同时，传统混合专家（Mixture-of-Experts, MoE）架构在金融场景应用中存在三大核心顽疾：一是人工预设专家分工边界，违背数据驱动的端到端学习原则，极易导致有效信号的人为遗漏；二是依赖辅助负载均衡损失实现专家调度，为平衡负载强制将Token分配给语义不匹配的专家，引发严重的专家同质化问题；三是冷启动阶段路由随机化，易出现专家塌陷与训练崩溃，难以适配金融数据的低信噪比特性。

针对上述问题，本章设计1个全局共享专家+8个动态路由专家的双轨自专业化MoE架构，全程遵循无硬编码、纯数据驱动的设计原则：输入为第三章单层MB-PSTSA-GNN输出的多频率时空融合特征，严格遵循DeepSeek-V3官方原生路由规范，仅通过动态偏置项实现负载均衡，彻底移除辅助平衡损失与专家动态拆分/休眠机制；采用Top-2稀疏激活规则，每个Token恒激活1个共享专家+2个路由专家；以全链路复用的7类频率嵌入为核心锚点，配套适配的表征空间正交化正则化约束，从梯度层面阻断专家特征同质化；共享专家与路由专家全程参与端到端联合训练，无独立预训练与参数冻结，保障全链路训练节奏统一；模块输出市场状态自适应的高质量特征表示，无缝衔接后续第五章强化学习决策模块。

4.1 模块整体架构与设计原则

本章所提自专业化MoE模块整体采用双轨并行架构，完整保留端到端数据驱动的学习范式，无任何人工预设的专家分工规则。模块输入为第三章输出的多频率时空融合特征，经RMSNorm层归一化后，并行输入全局共享专家分支与动态路由专家分支：共享专家对所有输入Token恒激活，不参与路由调度，学习全频率、全市场制度下通用的金融规律特征基底；8个路由专家通过门控网络实现Top-2稀疏激活，以Token中携带的频率嵌入为核心锚点，纯数据驱动下自动分化出适配不同频率、不同标的、不同市场制度的专属特征提取能力；两路专家输出经门控融合后，通过残差连接与原始输入特征合并，输出最终的自适应特征表示。

模块全程遵循三大核心设计原则：

1. 自专业化原则：无任何人工预设的专家分工边界，专家的特征聚焦方向完全由训练过程中的数据分布自动分化，仅通过架构约束与正则化保障分工的有效性，避免人为引入的模型偏见；
2. 无硬编码原则：全程无人工设置的路由阈值、负载强制分配规则、特征裁剪约束，仅通过DeepSeek-V3原生动态偏置项实现负载均衡，完全由数据驱动路由决策；
3. 无冗余优化原则：彻底移除传统MoE的辅助负载均衡损失，避免辅助损失与核心特征学习目标的梯度冲突，仅通过适配Top-2激活的表征空间正交化保障专家专业化，实现模型训练的去冗余优化。

模块基础超参数设置如下：单层MoE层，包含1个共享专家+8个路由专家，单Token固定激活1个共享专家+Top-2个路由专家，模型隐空间维度 $D_{model} = 256$ ，专家FFN层中间维度为 $4 \times D_{model}$ ，Dropout丢弃率设置为0.1，缓解模型过拟合。

4.2 输入特征适配：全频率嵌入的全链路承接

MoE模块的输入为第三章MB-PSTSA-GNN输出的多频率时空融合特征，该特征已完成FinCast范式分块实例归一化、全链路频率嵌入叠加、全连接多向同步交叉注意力融合，因此本章无需新增任何重复的频率嵌入设计，仅需保留Token中已携带的频率嵌入信息，作为路由决策的核心锚点，彻底避免特征冗余。同时补充可学习位置嵌入与资产属性嵌入，为MoE路由提供明确的特征锚点，引导专家实现纯数据驱动的专业化分化：

1. 可学习位置嵌入：为每个分块的时序位置分配可学习的位置嵌入 $E_n^{pos} \in \mathbb{R}^{D_{model}}$ ，编码Token在时序序列中的相对位置，捕捉金融时序的依赖关系，直接叠加到输入Token嵌入上；
2. 资产与市场状态嵌入：为每个标的/行业/板块分配可学习嵌入，编码标的专属属性，引导路由专家自动分化出对应不同资产类别的自专业化能力，叠加到对应序列的所有Token上。

4.3 自专业化双轨专家网络结构设计

本章采用双轨并行的专家结构设计，分为全局共享专家层与动态路由专家层，两层专家共享完全一致的输入特征，无人工预设的分工边界，完全由数据驱动实现自专业化分化，全程端到端联合训练。

4.3.1 专家基础单元结构

每个专家单元均采用基于SwiGLU激活函数的前馈网络（FFN）结构，适配金融数据的非线性特征拟合需求，避免传统ReLU激活函数的神经元死亡问题，形式化定义为：

$$\text{Expert}(x) = (\text{Swish}(xW_1) \odot xW_2)W_3 \quad (4.1)$$

其中， $W_1, W_2 \in \mathbb{R}^{D_{model} \times 4D_{model}}$ 为升维层权重，将输入特征映射至4倍隐藏维度； $W_3 \in \mathbb{R}^{4D_{model} \times D_{model}}$ 为降维层权重，将特征映射回原始模型维度； $\text{Swish}(x) = x \cdot \sigma(x)$ 为Swish激活函数， $\sigma(\cdot)$ 为Sigmoid激活函数， $\odot$ 为逐元素乘积。

所有专家权重均采用Xavier均匀初始化，保证训练初始阶段的梯度稳定性，初始化公式为：

$$W \sim U\left(-\sqrt{\frac{6}{D_{model} + 4D_{model}}}, \sqrt{\frac{6}{D_{model} + 4D_{model}}}\right) \quad (4.2)$$

4.3.2 全局共享专家层

全局共享专家层仅包含1个并行专家单元，核心规则为：对所有输入Token 100%全激活，不参与门控路由调度，无Token分配限制，全程参与端到端训练不冻结。其核心作用为学习全量金融数据的通用特征基底，为所有输入Token提供统一的特征锚点，无任何人工预设的“宏观特征”分工边界，训练过程中自动学习跨所有标的、频率、周期、市场制度的共性模式，为路由专家的专业化分化提供稳定的特征基础。

4.3.3 动态路由专家层

动态路由专家层包含8个并行的同结构专家单元，核心规则为：仅通过门控路由网络实现稀疏激活，每个Token仅激活Top-2个路由专家，无任何人工预设的“细分域/频率/标的/周期”分工，仅通过DeepSeek-V3动态偏置项实现负载均衡，无任何强制Token分配规则。其核心作用为在共享专家的特征基底上，以Token中携带的频率嵌入为核心锚点，纯数据驱动下自动分化，学习不同Token对应的专属数据模式，训练过程中自然形成对应不同频率、不同标的、不同市场制度的自专业化能力，与共享专家形成特征互补。

4.4 全频率感知的无硬编码纯数据驱动路由机制

本章完全复用DeepSeek-V3官方技术报告的原生路由方案，彻底移除所有辅助平衡损失，仅以Token中携带的0-6索引对应频率嵌入为核心引导，实现专家的自专业化分化，无任何人工预设的专家-频率绑定规则，完全符合本文「无硬编码、纯数据驱动」的研究范式。

4.4.1 门控路由权重计算

采用DeepSeek-V3原生的Sigmoid门控+Top-2路由机制，门控网络仅基于输入Token的隐向量与专家质心向量的内积，计算Token与专家的语义亲和度，Token中携带的频率嵌入会直接参与亲和度计算，无任何人工先验偏置，形式化公式为：

$$s_{n,k} = \text{Sigmoid}(x_n \cdot W_{gate,k}) + B_k \quad (4.3)$$

其中， x_n 为携带对应索引频率嵌入的输入Token， $W_{gate,k} \in \mathbb{R}^{D_{model}}$ 为第 k 个路由专家的门控权重向量， B_k 为第 k 个路由专家动态偏置项， $s_{n,k}$ 为Token n 对应专家 k 的路由亲和度得分。模型会自主学习7类频率嵌入与专家权重的匹配关系，纯数据驱动下实现专家分化——不同专家自动专精对应索引0-6的不同频率信号，适配从秒级微观到季度宏观的全频率特征提取。

基于亲和度得分，采用Top-2稀疏激活机制，每个Token仅选择亲和度最高的2个路由专家，仅保留选中专家的权重，其余专家权重置0，最大化专家的自专业化程度：

$$g_{n,k} = \begin{cases} s_{n,k}, & \text{if } k \in \text{Top2}(s_{n,1}, s_{n,2}, \dots, s_{n,8}) \\ 0, & \text{otherwise} \end{cases} \quad (4.4)$$

其中 $g_{n,k}$ 为Token n 对应专家 k 的最终门控权重。

4.4.2 动态偏置项负载均衡机制

完全移除传统MoE的辅助负载均衡损失，仅通过batch级的动态偏置项更新实现专家负载均衡，无任何强制Token分配规则，DeepSeek-V3官方原生更新规则如下：

1. 每训练1个batch，计算每个路由专家的实际负载 L_k ： $L_k = \frac{\text{该专家处理的Token数量}}{\text{该batch总Token数量}}$ ，以及专家平均负载 $L = 2/8 = 0.25$ （适配Top-2激活规则）；

2. 计算每个专家的负载偏差 $e_k = L_k - L$ ；

3. 执行偏置项更新：

$$B_k^{t+1} = B_k^t - \gamma \cdot \text{sign}(e_k) \quad (4.5)$$

其中， γ 为偏置学习率，冷启动初始阶段设置为0.01，训练稳定后降至0.001（DeepSeek-V3官方默认值）。

该机制的核心逻辑为：若专家实际负载高于平均负载，则降低其偏置项以抑制路由选择；若实际负载低于平均负载，则提高其偏置项以鼓励路由选择。关键约束为：偏置项仅用于Top-2路由的排序，不参与门控权重的最终计算，完全干扰专家的核心特征学习，仅通过调整路由优先级实现负载均衡，彻底避免Token强制分配问题。

4.5 适配全频率感知的表征空间正交化方案

为彻底避免专家同质化、共享专家与路由专家的表征冲突问题，引入仅针对同Token激活专家的表征空间正交化正则化约束，完全适配1个共享专家+2个路由专家的激活模式，补充全频率感知的适配逻辑，从梯度层面阻断专家特征同质化的传导路径，与动态偏置项机制完全兼容，不干扰负载均衡与核心特征学习。

4.5.1 正交性正则化形式化定义

正交性正则化仅对同一个Token下被激活的专家集合施加约束，而非全局所有专家，既干扰路由的负载均衡目标，又能强制激活专家在同一输入下学习到完全正交的特征表征，核心公式为：

$$\mathcal{L}_o = \sum_{n=1}^N \left[\sum_{i \in A, B} \left(\frac{E_{n, shared}^\top E_{n, i}}{|E_{n, shared}|_2 |E_{n, i}|_2} \right)^2 + \left(\frac{E_{n, A}^\top E_{n, B}}{|E_{n, A}|_2 |E_{n, B}|_2} \right)^2 \right] \quad (4.6)$$

其中， N 为batch内的Token总数， A, B 为该Token激活的2个路由专家集合， $E_{n, shared}$ 为共享专家对Token n 的输出向量， $E_{n, A}, E_{n, B}$ 为2个激活路由专家对Token n 的输出向量。

4.5.2 全频率适配逻辑与训练稳定性保障

该正则化对本章双轨架构的适配逻辑分为两层：

1. 强制共享专家的特征基底与每个被激活的路由专家的专属特征在表征空间正交，从梯度层面彻底避免通用基底与频率专属特征的表征冲突，保障双轨专家的协同分化；
2. 强制2个同时激活的路由专家之间的特征空间正交，若同时激活的2个路由专家，对同一频率索引的特征表征高度相关，正则化会施加梯度惩罚，强制2个专家分别聚焦不同频率索引的互补性信号，从梯度层面彻底阻断专家同质化的传导路径，强化全频率引导的专业化分化效果。

为进一步保障训练稳定性，配套两项基础机制：一是所有专家输入前均采用RMSNorm层归一化，避免梯度爆炸与消失；二是专家输出融合后均采用残差连接，保障训练过程中的梯度流动性。正交性正则化的权重冷启动阶段设置为1e-5，稳定训练阶段提升至1e-4，仅作为辅助约束，不干扰模型核心优化目标。

4.6 MoE模块完整前向传播流程

本章所提自专业化MoE模块的完整前向传播过程形式化定义如下，全程严格遵循无硬编码、纯数据驱动的设计原则，完美适配「感知层→专家层」的核心架构链路：

1. 残差保存： $r = x$ ，其中 x 为第三章输出的、携带全链路0-6索引频率嵌入的多频率时空融合特征；
2. 层归一化： $x_{norm} = \text{RMSNorm}(x)$ ，对齐FinCast原生归一化规范；

3. 共享专家前向传播： $h_{shared} = \text{SharedExpert}(x_{norm})$ ，学习全频率、全市场通用的特征基底；
4. 路由亲和度计算：基于携带频率嵌入的Token，计算路由亲和度得分与动态偏置项；
5. Top-2稀疏激活与路由专家前向传播，生成全频率自适应的专属特征；
6. 特征融合与残差连接：

$$y = h_{shared} + h_{special} + r \quad (4.7)$$

$$y = h_{shared} + h_{special} + r \quad (4.7)$$

最终输出 y 为市场状态自适应的、全频率感知的特征表示，无缝衔接后续第五章GRPO深度强化学习决策模块。

第五章 基于GRPO的深度强化学习自适应投资组合优化模块

动态投资组合优化的本质是典型的离散时间序列决策问题，传统深度强化学习算法在该场景中存在三大核心瓶颈：一是基于Actor-Critic框架的PPO算法依赖Critic网络进行价值估计，金融数据的高噪声特性易导致价值估计偏差，引发策略更新不稳定；二是传统区间型奖励函数无法实现单步决策的即时反馈，策略学习效率低下；三是策略优化目标与实盘约束脱节，易出现回测绩效优异但实盘表现大幅回撤的问题。

针对上述问题，本章严格遵循投资组合优化领域的通用学术规范，承接第一章MDP形式化定义，100%对齐《Deep Reinforcement Learning for Optimal Portfolio Allocation》的核心定义与设计范式；采用群组相对策略优化（Group Relative Policy Optimization, GRPO）算法替代传统PPO算法，摒弃Critic网络，通过群组采样与相对优势计算实现无偏的策略梯度估计，在金融高噪声环境下具备更优的训练稳定性与样本效率；核心奖励函数采用目标论文原生的微分夏普比率（Differential Sharpe Ratio, DSR），实现单步决策的即时反馈，配套符合实盘规则的约束嵌入机制；同时结合全链路训练规范，完成冷启动流程统一、策略网络架构优化、早停机制规范等针对性改进，构建端到端的自主资产配置优化框架。

5.1 动态投资组合优化的MDP适配性定义

本章承接本文第一章1.1节的完整MDP形式化定义，核心优化目标、五要素底层逻辑均与第一章保持完全一致，此处仅针对GRPO算法的序列决策特性，对MDP五要素中与算法适配的细节做补充定义，不重复核心形式化表述。核心优化目标与第一章保持一致：

$$\max_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) \right] \quad (5.1)$$

5.1.1 动作空间

本章将智能体的动作定义为连续型的投资组合权重分配，针对包含 N 个风险资产+1个现金资产的投资标的池， t 时刻的动作 a_t 为 $N+1$ 维连续向量 $w_t = [w_{1,t}, w_{2,t}, \dots, w_{N,t}, w_{c,t}]$ ，其中 $w_{i,t}$ 为风险资产 i 的持仓权重， $w_{c,t}$ 为现金资产权重，动作空间全面采用《Deep Reinforcement Learning for Optimal Portfolio Allocation》原生设计的三大实盘硬约束：

1. 全仓约束: $\sum_{i=1}^N w_{i,t} + w_{c,t} = 1$, 组合始终满仓运行;
2. 多头无杠杆约束: $0 \leq w_{i,t} \leq 1$, $0 \leq w_{c,t} \leq 1$, 禁止做空与杠杆交易, 无额外非100%的单资产持仓上限;
3. 行业集中度约束: 单个行业内所有资产的权重之和不超过0.25, 避免组合过度集中。

为让神经网络输出自动满足上述约束, 采用带约束的softmax函数对网络原始输出进行处理, 将无界的网络输出映射到合规的权重空间, 无需额外的可行域硬投影操作, 避免破坏策略网络输出的梯度连续性。

5.1.2 状态空间

状态空间是智能体感知市场、执行自主决策的核心载体, 本章融合全频率时空融合特征、组合持仓特征与全局风险指标特征, 构建标准化的矩阵化状态空间, 严格规避未来信息泄露。对于 N 个风险资产+1个现金资产, 回看窗口 $T = 60$ 个交易日, t 时刻的观测状态 s_t 为维度 $[(N+1) \times T]$ 的矩阵, 形式化定义为:

$$s_t = \begin{pmatrix} w_{1,t} & r_{1,t-1} & \cdots & r_{1,t-T+1} \\ w_{2,t} & r_{2,t-1} & \cdots & r_{2,t-T+1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{N,t} & r_{N,t-1} & \cdots & r_{N,t-T+1} \\ w_{c,t} & vol_{20,t} & \frac{vol_{20,t}}{vol_{60,t}} & VIX_t \end{pmatrix} \quad (5.2)$$

其中, 状态矩阵各组件定义为:

- 第一列: t 时刻进入交易时的当前组合权重向量, 反映智能体当前持仓状态;
- 主体部分: 每个风险资产对应行的第2至第 T 列, 为该资产过去60个交易日的日度对数收益率, 为前置特征提取模块提供标准化输入;
- 最后一行: 三个全局市场风险指标, 分别为市场基准指数20日滚动波动率、20日与60日波动率比率、市场隐含波动率指数 (VIX) , 刻画整体市场环境。

所有连续型特征均采用扩展窗口标准化, 仅使用 t 时刻之前的历史数据计算均值与标准差, 严格规避未来信息泄露。

5.1.3 状态转移机制

本章采用无模型的DRL框架, 无需显式建模状态转移的概率分布, 状态转移过程由符合实盘交易规则的市场回放环境隐式决定, 完全满足马尔可夫性:

- 环境底层为真实的金融历史行情数据, 状态转移完全由真实的市场价格演化决定, 无任何人工构建的环境动力学模型;
- 对于给定的当前状态 s_t 和动作 a_t , 下一个状态 s_{t+1} 由 $t+1$ 日的真实市场行情与动作 a_t 决定的持仓权重唯一确定;
- 组合价值计算与再平衡流程严格遵循实盘交易规则: t 日收盘后计算组合总价值, 按照动作 a_t 对应的目标权重执行调仓, 向下取整计算可买入股数, 剩余资金计入现金余额, 基于 $t+1$ 日收盘价格计算新的组合状态, 完成一次状态转移。

5.1.4 奖励函数

奖励函数是DRL策略优化的核心导向，本章严格遵循目标论文的原生设计，以风险调整后收益最大化为核心目标，采用微分夏普比率（DSR）作为单步核心即时奖励，将区间型的夏普比率转化为可在线更新的单步微分形式，实现每一步决策的即时反馈，配套实盘交易成本惩罚项，同时复用第二章统一的EWMA递归更新体系，保障全模型统计量一致性。

首先，基于第二章统一的EWMA体系，定义组合收益一阶矩 A_t 和二阶矩 B_t 的递归更新公式，衰减系数 $\eta = 2/253$ （与目标论文官方设置完全一致）：

$$\begin{cases} A_t = A_{t-1} + \eta(R_t - A_{t-1}) \\ B_t = B_{t-1} + \eta(R_t^2 - B_{t-1}) \end{cases} \quad (5.3)$$

其中， R_t 为 t 时刻投资组合的单日简单收益率，初始值 $A_0 = 0, B_0 = 0$ 。

微分夏普比率的形式化定义与目标论文完全对齐，作为单步核心即时奖励：

$$DSR_t = \frac{B_{t-1}(R_t - A_{t-1}) - \frac{1}{2}A_{t-1}(R_t^2 - B_{t-1})}{(B_{t-1} - A_{t-1}^2 + \epsilon)^{\frac{3}{2}}} \quad (5.4)$$

其中 $\epsilon = 1e-8$ 为数值稳定性保护项，避免分母为0。

为控制组合换手率，降低交易成本对实盘收益的侵蚀，加入线性换手率惩罚项，最终完整奖励函数为：

$$R_t^{final} = DSR_t - \lambda_{cost} \cdot |w_t - w_{t-1}|_1 \quad (5.5)$$

其中 $\lambda_{cost} = 1.0$ 为惩罚系数，可根据交易成本水平灵活调整。同时对最终奖励进行裁剪， $R_t^{final} \in [-10, 10]$ ，避免极端异常值导致的训练不稳定。

5.1.5 折扣因子

折扣因子设置为 $\gamma = 0.9$ ，配套广义优势估计的参数 $\lambda = 0.95$ ，平衡策略优化的偏差与方差，适配日度调仓的投资组合决策场景，既不过度弱化长期收益的影响，也不放大短期噪声的干扰，与第一章核心定义完全对齐。

5.2 面向金融场景的GRPO算法适配性改进

GRPO算法通过群组采样与相对优势计算，摒弃了传统PPO算法中的Critic网络，大幅减少了模型参数量与训练不稳定性，在金融高噪声、低信噪比的场景中具备天然适配性。本章针对金融投资组合场景完成四大核心改进：实现DSR即时奖励与GRPO step级优化的深度融合，采用GRPO原生旧策略网络约束策略更新幅度，采用均值-标准差归一化优势函数适配金融收益分布，配套裁剪机制保障策略更新的稳定性。

5.2.1 GRPO算法核心逻辑与金融场景适配性

GRPO算法的核心逻辑是：对同一个初始状态，采样多条独立的动作轨迹组成一个群组，通过组内轨迹的相对表现计算优势函数，无需Critic网络进行价值估计，彻底避免了价值估计偏差导致的策略更新不稳定问题，完美适配金融数据的高噪声特性。其与投资组合场景的核心适配性体现在三点：

1. 无Critic网络设计，减少了一半的模型参数量，避免了Critic网络过拟合历史数据导致的策略偏差，提升了模型的样本外泛化能力；

2. 组内相对优势计算，仅关注同一状态下不同动作的相对优劣，屏蔽了市场整体涨跌带来的奖励偏移，让策略聚焦于捕捉相对收益信号；
3. step级梯度回传机制，可完美适配DSR单步即时奖励，实现每一步决策的即时梯度反馈，大幅提升策略学习效率。

5.2.2 DSR即时奖励与GRPO step级优化的融合方案

针对GRPO原生的token级梯度更新逻辑，本章设计了完全对齐目标论文范式的step级群组采样方案，既保留了DSR的即时反馈特性，又符合GRPO的核心优化逻辑，彻底消除完整episode轨迹采样的计算冗余，完整实现流程如下：

1. step级群组采样：对每个交易日（step）的市场状态 s_t ，采样 $G = 64$ 条独立的调仓动作组成一个群组（GRPO官方默认组大小），每个动作对应一个投资组合权重分配，无需等待完整episode结束；
2. 单步即时奖励计算：对每个采样动作，计算该step对应的单步DSR即时奖励 $R_{t,g}$ ，无需累积完整episode总奖励，目标论文已严格证明，最大化单步DSR的累积和等价于最大化全局夏普比率，确保单步优化与长期目标完全对齐；
3. step级梯度回传：基于该step内64个动作的奖励，计算组内相对优势函数，执行step级梯度回传，更新策略网络参数，实现DSR即时奖励的梯度回传，大幅降低计算开销，同时保留DSR的即时反馈特性。

5.2.3 策略更新幅度约束方案

本章彻底删除独立的动态滚动参考模型设计，采用GRPO原生的旧策略网络 $\pi_{\theta_{old}}$ 实现策略更新幅度约束，与主策略网络共享完全一致的架构，同步初始化，无额外参数设计，消除重复网络的冗余问题，具体方案如下：

1. 更新规则：每完成1个batch的轨迹采样与梯度更新后，将主策略网络权重完全同步到旧策略网络，即 $\theta_{old} \leftarrow \theta$ ，替代原固定步长滚动同步，完全符合GRPO原生逻辑；
2. 约束机制：仅保留GRPO原生的重要性采样权重裁剪机制（clip阈值0.2），实现策略更新幅度约束，无需额外KL散度惩罚，消除双重约束冗余，避免梯度更新目标冲突。

5.2.4 优势函数适配优化

金融收益具有典型的尖峰厚尾特性，本章结合奖励裁剪机制，采用GRPO原生的均值-标准差归一化优势函数，替代原秩归一化方案，既解决了厚尾分布极值带来的估计偏差，又完整保留了DSR奖励中风险调整后收益的核心信息，完全对齐《Deep Reinforcement Learning for Optimal Portfolio Allocation》基准论文原生设计，形式化定义如下：

对同一群组内 G 个采样动作的即时奖励 $R_{t,1}, R_{t,2}, \dots, R_{t,G}$ ，计算归一化后的相对优势函数：

$$\hat{A}_g = \frac{R_{t,g} - \mathbb{E}[R_{t,g}]}{\text{std}(R_{t,g}) + \epsilon} \quad (5.6)$$

其中， $\mathbb{E}[R_{t,g}]$ 为组内奖励均值， $\text{std}(R_{t,g})$ 为组内奖励标准差， $\epsilon = 1e-8$ 为数值稳定性保护项。该方案与奖励裁剪形成互补，既通过裁剪消除了极端值影响，又通过均值-标准差归一化完整保留了DSR奖励的风险调整信息，与基准论文范式完全对齐。

5.2.5 GRPO最终优化目标

结合上述改进，本章最终的GRPO策略优化目标函数形式化定义为：

$$\mathcal{L}_{GRPO} = -\frac{1}{G} \sum_{g=1}^G \min(r_g \cdot \hat{A}_g, \text{clip}(r_g, 1 - \epsilon, 1 + \epsilon) \cdot \hat{A}_g) \quad (5.7)$$

其中， $r_g = \frac{\pi_{\theta}(a_g|s_g)}{\pi_{\theta_{old}}(a_g|s_g)}$ 为动作的重要性采样权重， $\hat{A}_g$ 为均值-标准差归一化后的相对优势函数， $\epsilon = 0.2$ 为裁剪阈值。采用AdamW优化器最大化该策略目标，更新策略网络的参数 θ 。

5.3 策略网络架构与硬约束嵌入设计

本章所提策略网络完整融合前文的多频率时空图神经网络、自专业化MoE模块，实现从原始数据输入、特征提取到投资组合决策输出的端到端闭环，同时配套符合实盘规则的硬约束嵌入机制，确保模型输出始终满足交易规则要求。

5.3.1 策略网络整体架构

策略网络采用高斯策略头适配连续动作空间，与《Deep Reinforcement Learning for Optimal Portfolio Allocation》原文设计完全对齐，整体前向传播流程严格遵循「FinCast Token化→单层MB-PSTSA-GNN感知层→MoE专家层→策略头输出」的核心架构链路，形式化定义如下：

$$\pi_{\theta}(a|s) = \mathcal{N}(\text{Tanh}(\mu_{\theta}(s)), \sigma_{\theta}^2) \quad (5.8)$$

其中，网络完整前向传播链路为：

1. 输入层：接收标准化的MDP状态矩阵，执行第二章所述的FinCast范式分块实例归一化与Token化处理，生成标准化的输入Token；
2. 特征编码层：通过第三章单层MB-PSTSA-GNN，提取时序依赖与跨资产空间关联特征，输出多频率时空融合特征；
3. 自适应特征层：通过第四章的自专业化MoE模块，输出市场状态自适应的特征表示，适配异构市场环境的信号捕捉需求；
4. 策略头：仅保留一层全连接层，直接基于MoE输出的资产级特征，输出动作的均值 $\mu_{\theta}(s)$ ，同时学习可学习的对数标准差 $\log \sigma$ ，限制范围为 $[-20, 2]$ ，保证数值稳定性；
5. 约束映射层：通过带约束的softmax函数，将高斯分布采样的动作映射到合规的投资组合权重空间，满足所有实盘硬约束。

本架构彻底删除原设计中的池化层与额外的全连接层，避免资产细粒度信息丢失与特征变换冗余，完美保留不同资产的差异化特征，与投资组合权重分配的核心目标完全对齐。

5.3.2 硬约束嵌入机制

为确保模型输出始终符合实盘交易规则，本章采用「带约束softmax硬映射+奖励函数软约束」的双重约束嵌入方案，与目标论文原生设计完全对齐，彻底删除可行域硬投影机制，避免破坏梯度连续性：

1. 硬映射机制：在策略网络输出层采用带约束的softmax函数，将网络原始输出自动映射到满足全仓、无杠杆、行业集中度约束的权重空间，从输出源头保障动作合规性，无需额外的事后修正；
2. 软约束嵌入：在奖励函数中加入约束违反惩罚项，针对调仓频率超限等违规行为，施加对应的奖励惩罚，引导模型学习合规的决策行为，进一步强化实盘适配性。

5.4 训练进程规范与收敛性保障

本章严格遵循《Deep Reinforcement Learning for Optimal Portfolio Allocation》原生训练范式，与前文MoE模块、特征提取模块完全联动，定义标准化的三阶段全链路端到端训练进程，不使用MVO权重做行为克隆，仅采用目标论文原生冷启动方案，配套收敛性保障机制，确保模型训练稳定可控，避免过拟合历史数据。

5.4.1 滚动窗口训练范式（全面采用目标论文原生设计）

本研究全面采用《Deep Reinforcement Learning for Optimal Portfolio Allocation》原生的滚动窗口训练范式，严格遵循时序因果性，无任何未来信息泄露，具体设计如下：

1. 整体窗口划分：全量数据划分为10个滑动窗口组，每组时间偏移1年；
2. 单组内时序分割：每组包含7年完整数据，严格按照前5年为训练集 → 第6年为验证燃烧期（burn year）→ 第7年为严格样本外测试集划分；
3. 增量迭代规则：前一个窗口训练得到的最优模型checkpoint，作为下一个窗口训练的种子模型，实现增量学习与市场状态自适应。

5.4.2 统一三阶段训练进程规范

全模型采用端到端联合训练，无分模块独立预训练，无学习率预热，所有模块参数同步更新，训练进程分为三个阶段：

1. 冷启动预热期（前10个epoch）：采用全量训练数据进行训练，固定GAT空间注意力的邻接矩阵掩码，仅放开注意力权重学习；MoE模块关闭正交性正则化，路由专家偏置项初始化为0，仅用动态偏置项调整负载；GRPO模块固定策略网络的对数标准差为-5，关闭策略裁剪机制，仅用DSR核心奖励进行策略优化。本阶段核心目标是让全模型同步学习基础的市场规律与调仓逻辑，避免训练初期策略崩溃。
2. 稳定训练期（10-100个epoch）：采用全量训练数据进行训练，放开GAT邻接矩阵滚动更新，开启Dropout缓解过拟合；MoE模块开启正交性正则化，偏置学习率降至0.001，完成专家自专业化分化；GRPO模块开启策略裁剪机制，放开对数标准差学习范围，优化DSR累积奖励。本阶段每10个epoch在验证集上进行一次性能评估，以验证集DSR为核心监控指标，监控模型的收敛情况与泛化能力。
3. 泛化验证与早停期（100个epoch后）：仅用验证集数据进行滚动验证，不更新模型参数；若连续5-10个epoch验证集DSR无提升，触发早停机制，终止训练，保留验证集性能最优的模型权重，彻底删除样本外数据触发早停的设计，避免未来信息泄露与过拟合。

5.4.3 收敛性保障机制

为确保模型训练稳定收敛，配套四项核心机制：

1. 优化器超参数设置：采用AdamW优化器，初始学习率 $3e-4$ ，训练过程中线性退火至 $1e-5$ ，权重衰减0.05，梯度裁剪阈值 $\max_grad_norm = 0.5$ ，避免梯度爆炸；
2. 策略更新约束：采用GRPO原生裁剪机制，限制策略更新的最大步长，避免策略更新幅度过大导致的性能崩塌；
3. 滚动窗口增量训练：采用7年训练、1年验证、1年测试的滑动窗口增量训练范式，前一个窗口训练的最优模型作为下一个窗口训练的种子模型，保障模型决策能力的增量迭代；
4. 过拟合抑制机制：在特征提取层与策略头中加入Dropout层，配合权重衰减与层归一化，缓解模型过拟合；同时采用组归一化替代批次归一化，避免小批次训练下的统计量偏差，提升模型泛化能力。

5.5 回测与验证细节（全面采用目标论文原生设计）

具体规范如下：

1. 标的池：沪深300；
2. 全量数据区间：2010年-2026年，日度复权收盘价数据；
3. 调仓规则：日度调仓，每个交易日执行一次权重再平衡；
4. 初始资金：每个回测周期初始资金为100万全现金仓位；
5. 交易执行：严格按照整手股数交易，剩余资金计入现金账户，原生无交易成本、无滑点设置，可通过奖励函数惩罚项模拟交易成本；
6. 无风险利率：采用2.5%固定无风险利率，用于夏普比率、DSR指标计算；
7. 对照基准设置：
 - 核心对照基准：MVO均值-方差优化模型，采用60日滚动窗口估计收益均值，Ledoit-Wolf收缩估计协方差矩阵，以最大化夏普比率为优化目标；
 - 辅助对照基准：沪深300大盘指数。

5.6 样本外泛化性增强机制

针对金融市场非平稳性导致的样本外性能退化问题，本章配套两项核心泛化性增强机制，提升模型的实盘适配能力：

1. 市场制度自适应机制：基于MoE模块的自专业化专家分化，模型可自动识别市场制度切换，激活适配当前市场环境的路由专家，避免市场制度切换时的性能退化，实现异构市场环境下的自适应决策；
2. 全链路特征一致性机制：从输入层到决策层，全程采用统一的标准化体系、统一的EWMA更新体系、统一的频率嵌入体系，避免特征分布偏移导致的样本外性能退化，保障模型在未知市场环境下的特征提取稳定性。